

智算中心发展趋势报告



中国软件评测中心

(工业和信息化部软件与集成电路促进中心)

基础软件质量控制与技术评价工业和信息化部重点实验室

二〇二六年六月

目 录

一、 情况概述	1
(一) 智算中心的内涵	1
(二) 智算中心的关键技术	2
1. 芯片级高速互联	2
2. 集群调度与运维	3
3. 智能原生云平台	4
4. 制冷与算电协同	5
二、 现状与趋势	6
(一) 向词元工厂演进	6
(二) 系统性升级改造	7
(三) 边缘中心快增长	8
(四) 算力边界快拓展	9
三、 问题及建议	9
(一) 电力能源供应瓶颈	9
(二) 供需错配利用率低	10
(三) 生态及供应链风险	11
(四) 私有重复建设严重	12
参考文献	13

一、情况概述

智算中心是专注服务于智能计算的现代化算力设施。区别于传统通用数据中心，它支撑大模型训练和推理、科学计算、智能制造、自动驾驶等高复杂度高价值智算场景。

国家自 2020 年将算力首次纳入“新基建”范畴以来，相继于 2023 年实施“东数西算”工程，2025 年推出“人工智能+”行动，并在“十五五”规划中进一步强调智能算力统筹发展和超大规模智算集群建设。据工信部公开数据，截至 2025 年底，我国智能算力规模超过 1590 EFLOPS，已建成万卡智算集群42个，位居全球前列^[1]。截至 2026 年 3 月，全国智能算力总规模已达 1882EFLOPS，在用算力中心标准机架达 1445 万架，已建成超 70 条算力大通道^[2]。

与此同时，超节点等新型高密度计算架构不断涌现，集群规模也向十万卡级互联大步迈进。智算中心正在从支撑大模型训推任务的“算力设施”升级为“AI 工厂”，发展重心从规模扩张全面转向质量效能与应用落地，迈入以“普惠赋能”、“互联互通”和“算电协同”为特征的高质量发展攻坚期。

（一） 智算中心的内涵

2024 年 8 月 19 日工信部等十一部门联合印发《关于推动新型信息基础设施协调发展有关事项的通知》的附件中对新型基础设施、智算中心等 9 个名词做出解释。智算中心，即人工

智能计算中心，是基于人工智能理论，采用人工智能计算架构，提供人工智能应用所需算力服务、数据服务和算法服务的一类算力基础设施。该阐释主要聚焦算力服务、数据服务和算法服务，核心在于满足生成式大模型的训推任务展开。这适应于当时“百模大战”和“算力荒”的 AI 产业发展状况，着力“建好”三大类服务。但在 DeepSeekV4、Qwen3.6 等国产大模型强势崛起、推理服务需求井喷的当前，智能体应用即将爆发的前夜，智算中心实现了规模的量级跃升与增值服务质的飞跃。

智算中心的内涵正在从“提供算力资源”升级为“生产交付智能”。早期智算中心主要解决大模型训练阶段的算力供给问题，核心能力聚集于算力、数据和算法服务。随着大模型进入推理和智能体应用阶段，智算中心的价值边界持续拓展。一是从资源供给转向全栈 AI 服务，成为持续生产词元（Token）和智能服务的“AI 工厂”。二是从单体中心转向跨区域互联互通，构建全国一体化算力网络。三是从单纯 IT 基础设施转向与电力、制冷、绿能深度耦合的“算电系统”。概括而言，这一升级可凝练为“服务升级、互联互通、算电协同”的新特征。

（二） 智算中心的关键技术

1. 芯片级高速互联

模型训练的参数面网络和模型推理服务质量都要求严苛的低时延与大带宽性能。为此，智算中心架构走向构建一个芯

片间高速互联的超级计算系统，如超节点和万卡集群。二者分别是从纵向扩展（Scale-Up）和横向扩展（Scale-Out）技术路线来实现算力芯片间的高效互联。

在 Scale-Up 方面，英伟达采用其私有的 NVLink 专用通信协议技术，实现数百 GB/s 带宽的 GPU 间高速点对点互联；华为通过自研灵衢（Unified Bus）协议联通 CloudMatrix384 超节点。

在 Scale-Out 方面，英伟达主要推行 IB（InfiniBand）专业网络技术；其次是基于以太网的 RoCE（RDMA over Converged Ethernet）协议；还有如超以太网联盟的 UEC 协议等基于开放标准的组网方案。

此外，光电互连技术通过光模块、硅光子技术、CPO（光电共封装）、LPO（线性驱动光模块）及 OCS 光电交换等方案，为芯片互联提供更高带宽密度、更低功耗、更低时延、更远距离的能力。

2. 集群调度与运维

集群是智算中心的核心，涉及到算力资源池化、调度、运维三大技术环节。池化是基础，调度、运维是用好的关键。

资源池化可以有效降低资源碎片化来提升资源利用率。它利用虚拟化、容器、切片等软件定义技术，将计算、存储、网络资源进行抽象、整合，形成统一资源池，实现细粒度切分、

弹性扩展、动态加载、按需分配、即时回收的资源全生命周期管理。

集群调度是对算力资源进行统一感知、抽象、分配、编排和优化管理的一套系统性技术。它根据任务需求、资源状态和优化策略，将任务动态、高效地映射匹配到合适的计算资源节点上执行，并具备容错保障和多租户隔离等安全措施。调度系统通过 API 调用驱动资源访问逻辑接口，为上层业务提供一致、简洁的集群访问操作视图。从任务执行层面看，业务系统通过任务排队、优先级等方式实现任务和资源的逻辑绑定执行；从资源管理层面看，调度系统根据任务的时序特征，动态规划资源的启动、关停、配额预留等来弹性供给资源。

集群运维管理系统通过对集群中的服务器、存储、网络、软件及计算任务进行全面观测，构建“可观测、可诊断、可自愈”三位一体的运维保障技术体系，打造全栈故障感知、在线诊断等智能化运维能力，确保智算集群的高可用性和应用服务的连续稳定运行。

3. 智能原生云平台

智算中心正从“算力资源”租赁模式向“智能工厂”服务模式转型升级，云服务化是其发展的必然趋势。在智算集群的基础上，智算中心采用云原生、低代码等技术手段打造面向“数据、模型、知识、智能体、应用”等应用构建要素的云化工程

平台及工具集，来有效支撑大模型即服务、智能体即服务的应用赋能。

模型即服务提供模型训练和推理全生命周期服务，实现覆盖数据准备、模型训练、性能评估、优化压缩、部署上线及在线监控等模型工程能力。智能体即服务构建智能体设计运营的工程化闭环能力，实现智能体理解目标、自主规划、协同决策、工具集成、记忆构建、测试验证、部署运行等开发运维一体化集成环境，不再是软件服务交付功能和界面，而是把智能体作为交付对象来代理执行任务并呈现最终结果。凭借此类服务，用户无需配置管理复杂基础设施，仅需按需定制即可快速搭建端到端的智能业务服务。

4. 制冷与算电协同

智算中心单机柜功率密度普遍高达数十千瓦至数百千瓦，传统风冷已难以满足散热需求，风液协同制冷、浸没式液冷、自然冷源利用等方案已成为必选项。配套的余热回收系统可大幅削减制冷能耗，将 PUE 控制在 1.08 至 1.2 之间，进而有效破除制约算力提升的“散热墙”。

算电协同核心在于双向赋能。一方面，将算力设施作为可调度的柔性负荷优化电网运营，另一方面，调整算力布局通过绿电直连来降低成本，实现“算优化电，电支撑算”的良性互动。在算优化电方面，依托 AI 对计算负载、绿电出力及市场电价

进行多尺度预测，构建算力任务的动态调度，实现电网载荷的柔性调节。当电网负荷高攀或绿电供应不足时，主动限制或迁移非实时计算任务；当电网负荷低谷或绿电供应充足时，弹性扩展后台批处理、数据训练等可延迟类算力负载。在电支撑算方面，智算中心就近消纳绿电，结合分布式储能与虚拟电厂聚合控制，构建“源网荷储算”一体化协同运行体系，为智算中心提供稳定、低成本、绿色的电力保障，破解算力发展的能源瓶颈。

制冷与算电结合起来，形成“能源-算力-热管理”三位一体调节机制。通过综合智控平台实时感知 IT 负载、温度及电力状态，动态调节制冷输出与电力分配，如电力高峰时提升冷量、低谷时降低能耗、绿电充裕时优先利用，从而实现电冷协同与能效最优。

二、现状与趋势

（一） 向词元工厂演进

生成式人工智能已从训练时代全面进入“推理+智能体”乃至物理 AI 的工业化生产阶段。未来的智算中心不再仅是存储数据和算力资源的仓库，而是 7x24 小时持续运转，投入电力和算力资源，可标准化生产交付词元的“AI 超级工厂”。智算中心的核心价值，正从“拥有多少算力”以匹配租赁需求，转向“产生多少词元”的高附加值智能服务。这是对商业模式、核心指

标和建设逻辑的根本性重构。

词元正在成为人工智能时代的统一计量单位，也可称为“智能代币”。当大模型针对一个复杂问题生成若干词元的回答时，其背后不仅消耗了算力、调用知识库、还可能触发一连串智能代理行为。此时，词元便成为承载这些价值交换的基本商品。在此背景下，客户的关注重点正从传统的“卡时计费”标准，转向词元的使用成本与响应延迟；行业内部的衡量指标，也从算力资源利用率转变为算力与电力投入所对应的词元产出效率。相应地，商业模式也在由“资源出租”向“结果交付”演进，盈利路径更加灵活多样，毛利率有望提升，投资回报周期也因此大幅缩短。

（二） 系统性升级改造

随着 AI 工作负载从大规模预训练转向复杂推理与代理式任务，智算中心架构正加速走向异构化和专用化。传统的“CPU+GPU”二元智算模式，正被“GPU（训练）+LPU/NPU（推理）+CPU（调度与环境生成）+ASIC（专用场景）”的异构协同架构所取代，旨在实现算力效能的极致释放。

CPU 的角色发生根本性转变，从传统的“数据搬运工”升级为智能体 AI 时代的“系统总指挥”，承担任务编排、工具调用、逻辑推理和资源调度等核心职责。在这一趋势下，数据中心中 CPU 的重要性显著提升，其与 GPU 的配比已从 AI 训练时代

的 1:4 至 1:8 快速演进至 1:1 至 1:2 之间。

同时，智能体长上下文推理记忆和模型训练检查点缓存对低延迟存储提出更高要求，存储架构中靠近计算单元的外存普遍采用 NVMe SSD 全闪存介质。从网络层面看，随着 400Gb/s 参数面网络的普及，智算中心正朝着 800Gb/s 乃至 1.6Tb/s 更高带宽的新一代架构演进。

（三） 边缘中心快增长

随着全国一体化算力网架构从“八大枢纽、十大集群”向“枢纽-区域-边缘”三级协同的分布式体系加速演进，智算能力正从云端快速下沉至边缘和终端，形成了“前端轻载、后端强算”的高效协同模式。2026 年，端侧算力将进一步激发无处不在的智能“神经末梢”，AI 手机、智能汽车等终端设备已成为算力部署的新战场。

在枢纽节点利用率持续提升的同时，边缘用算需求呈现爆发式增长。端侧和边缘算力中心侧将承担 70-90%以上的日常推理、实时响应任务，以及数据预处理、本地化合规等计算工作。枢纽节点作为“中央厨房”，其高性能训练和大模型集中服务能力得到强化，但面对海量边缘数据的高频存取和访问一致性挑战，单一枢纽难以全部承接，必须依靠边缘数据中心进行有效补位。因此，中小规模边缘智算中心将在强劲需求的拉动下快速扩张，成为全国一体化算力网的重要延伸和必要支撑，

真正实现“算力跟着用户走、数据跟着场景走”。

（四） 算力边界快拓展

2026 年的算力版图正在经历一场深刻的结构性重塑。算力正从集中式资源，加速进化为一张覆盖空、海、地的分布式算力网络。“上天入海”的算力新基建正不断突破物理极限，拓展算力边界。

上海临港海底数据中心采用“海上风电直联+海水自然冷却”双技术融合，将海洋冷却、风电供电、模块化建设与智能化运维深度融合，实现了海上绿电与海底算力的协同发展。项目设计 PUE(电源使用效率)不高于 1.15，绿电供给率超过 95%^[7]，为破解 AI 时代算力激增与能源紧缺的矛盾提供了“中国方案”。之江实验室正牵头建设全球首个太空 AI 基础设施——“三体计算星座”。该计划规划总规模达 1000 颗计算卫星，初期组网正稳步推进，计划于 2032 年完成全面组网将构建成服务全球人工智能的太空算力网络。低轨卫星互联网与边缘计算的结合，正将算力延伸到远洋、沙漠、高空等过去的信息荒漠，真正实现全球无死角的智能覆盖。

三、 问题及建议

（一） 电力能源供应瓶颈

随着单机架功率和算力密度的持续提升，智算中心的电力消耗的急剧攀升，电费在运维成本中的占比已普遍超过 50%，

部分场景甚至更高。东部地区因算力需求集中导致电力供应日趋紧张，而西部地区虽然可再生能源资源丰富，却面临电力外送通道不足、就地消纳能力有限等现实挑战。

绿电供应、液体冷却、算电协同成为破解瓶颈的关键路径。然而，当前电网预留容量不足、峰谷调节能力有限、可持续冷却方案尚未成熟，形成了对智算中心规模化发展的硬约束。尽管政策层面已将“算电协同”纳入国家战略方向，但实际落地仍面临机制、标准、投资等多重困难，需长期推进。

未来应在两方面发力。一是强化算电协同规划，在智算中心布局阶段即与区域电网容量、绿电资源匹配度联动评估、耦合部署；在运营阶段探索建立源网荷储算一体化调度机制，激励算力设施主动参与电力系统实时调节。二是加快液冷等节能技术规模化应用，通过标准制定、财税激励等引导智算中心升级冷却架构来降低 PUE 和总能耗。

（二） 供需错配利用率低

当前，大模型推理能力不断增强，智能体应用需求激增，算力市场呈现供不应求现象，这正是杰文斯悖论的生动体现。然而，这并非总量上的绝对短缺，而是典型的结构性错配：合适的算力不够、低效的算力过剩；高端算力紧缺，低端与通用算力过剩；东部供应紧张，西部算力闲置；生态成熟的高端算力供不应求，而部分适配性较弱的国产芯片集群利用率偏低。

许多智算中心因供需脱节陷入闲置困境，实际利用率仅20-40%^[4]，部分国产芯片集群闲置率高达50-80%^[6]。这种结构性供需失衡原因涉及到芯片架构、软件生态、网络带宽、能源供应的多种因素。同时也是早期数据中心强调规模“重建设轻应用”，叠加算力需求预测偏差、跨区域调度不足等问题所致。

政策正推动全国一体化算力网建设和智算中心互联互通行动，以提升存量资源的利用率，效果仍在显现中。下一阶段，算力建设工作的关键不只是继续建设更大更新更快集群，还要推动算力标准化、平台互联互通和应用侧需求牵引来提升算力利用率。

（三）生态及供应链风险

面对当前国际环境，智算中心核心器件仍面临短缺和断供风险。高端 GPU 芯片、HBM 内存等关键部件依赖进口，受地缘政治限制和全球产能瓶颈影响，供应链脆弱，易出现“卡脖子”问题。

与此同时，国内产业链协同仍显不足。智算中心涉及计算存储芯片、服务器整机、网络设备、液冷系统、电力保障、基础软件等多个环节，上下游企业协同难度大、标准不统一，导致异构算力融合困难、资源碎片化严重，利用率偏低。相较于 CUDA 生态，国产平台软件生态尚不成熟，开发者迁移成本高，

应用落地周期长，难以快速形成良性“建用”闭环。

为应对上述挑战，需双管齐下强化生态建设和供应链风险防范。一方面，要加快构建自主可控的软件生态，通过政策引导、资金支持和产学研协同，加速国产算力框架、编译器、开发工具链的成熟，显著降低开发者迁移成本；推动行业标准统一，促进异构算力互联互通，提升资源利用率。另一方面，在供应链安全上，应实施多元化战略。加大本土高端芯片、内存、先进封装等关键技术的研发投入，加快国产替代步伐；同时积极布局海外多元供应链，降低单一来源依赖，全面提升智算中心建设的韧性和可持续性。

（四） 私有重复建设严重

人工智能大模型让人们既兴奋又担忧。对于高敏感行业和高价值企业而言，在确保数据不出域的前提下将 AI 深度融入业务流程已成为迫切需求。然而，受数据驻留、安全审计、等保合规等刚性监管要求驱动，私有化自建部署算力正逐渐成为其核心应用场景的“常态”权衡选择，也成为 AI 战略的“治理刚需”。博通《私有云展望2025》显示^[3]，69%的企业正在考虑从公有云迁移至私有云，92%的 IT 领导者高度信赖私有云的安全性及合规性。

然而，自建私有智算中心面临现实挑战：技术门槛极高，运维成本高昂，重复建设进一步放大了投资浪费。据相关调研，

企业自建智算集群平均利用率甚至低于 30%，少数项目仅为 10%^[5]。考虑到智算中心建设投资巨大（单 GW 级项目动辄数亿至数十亿元）、且生命周期通常 5-10 年，低利用率直接造成巨额资金闲置、能耗浪费和资源低效利用。

针对上述问题，建议加快推动“行业共享+区域共建”模式：一是鼓励行业协会或龙头企业牵头，建设行业级/区域级共享智算平台，实现算力统筹调度与共建共用；二是通过政策引导和市场化机制，推动私有边缘数据中心与公有及行业智算平台的互联互通和深度协同。

参考文献

- [1] 国务院新闻办公室。国新办新闻发布会 [EB/OL] (2026-01-21)[2026-07-09]. <http://www.scio.gov.cn/live/2026/37907/index.html>
- [2] 国务院新闻办公室。国新办新闻发布会 [EB/OL] (2026-04-21)[2026-07-09]. <http://www.scio.gov.cn/live/2026/38374/index.html>
- [3] Broadcom. Private Cloud Outlook 2025[EB/OL]. (2025-05-29)[2026-07-09]. <https://news.broadcom.com/releases/private-cloud-outlook-2025-report>.
- [4] 郭松峤。财联社一线调研 高端算力“饥渴难耐”VS 智算中心“吃不饱”，破局之路已在脚下 [EB/OL]. 财联社, (2025-09-26)[2026-07-09]. <https://www.cls.cn/detail/2156687>.
- [5] 贾丽。中国 AI 算力突围需打好三张牌 [N]. 证券日报, 2025-04-02 (A01). DOI:10.28096/n.cnki.ncjrb.2025.001711.
- [6] 贾天荣。部分国产芯片闲置率高达 80%? 智算中心建设“点刹”背后 [EB/OL]. IT 时报, (2025-04-28)[2026-07-09]. <https://mp.weixin.qq.com/s/6v08XH5U4tlxjJBjN1n0XA>.
- [7] 王自堃。陆数海算 绿色算力再提升 [EB/OL]. 中国自然资源报 (2026-02-13)[2026-07-09]. <https://www.iziran.net/news.html?aid=5457265>.